


**Statistisk inläring och dataanalys**  
**Projekt**  
**October 2, 2023**

---


## 1 Uppvärmning

Figure 1: Histogram av betyg skalad mellan 0 och 1



Låt  $B$  vara betyg för en skateboardåkare och trick. Vi vill skatta  $P(B > 0.6 | B > 0) = \frac{P(B > 0 | B > 0.6)P(B > 0.6)}{P(B > 0)}$  som  $\tilde{P}(B > 0.6 | B > 0) = \frac{\sum_i^4 \sum_j^{96} \text{trick}_{ij} \mathbf{1}_{\{[0.6, 1]\}}}{\sum_i^4 \sum_j^{96} \text{trick}_{ij} \mathbf{1}_{\{[0, 1]\}}} \approx 0.96$  Det här stämmer med utseendet på fig. 1.

Figure 2: Spridningsdiagram mellan run 1 och run 2



## 2 En frekventistisk modell

**Anm 1** Vår model för  $X_i$  är följande

$$X_i = \begin{cases} 0 & \text{om } V_i = 0 \\ Z_i & \text{om } V_i = 1 \end{cases}$$

där  $V_i \sim \text{Ber}(\theta_i)$  och  $Z_i \sim \text{Beta}(\alpha_i, \beta_i)$  det här är ekvivalent med att säga

$$V_i = \mathbf{1}_{\{x \neq 0\}}(X_i) \text{ och } Z_i = X_i | (V_i = 1)$$

eftersom det här är bara en transformation av stokastiska variabler ger stickprov från  $X_i$  oss ett stickprov för  $Z_i$  och  $V_i$

### (a) Skatta $\theta_i$

Låt  $x_{i[n]} = (x_{i1}, x_{i2}, \dots, x_{in})^T$  vara vår stickprov från samtliga trick skateboardåkaren  $i$  utförde.

$$L(\theta_i, \alpha_i, \beta_i | x_{i[n]}) = \prod_{j=1}^n f_{x_i}(x_{ij}) = \prod_{j=1}^n (1 - \theta_i) \mathbf{1}_{\{x=0\}}(x_{ij}) + \theta_i f_{Z_i}(x_{ij}) \mathbf{1}_{\{x \neq 0\}}(x_{ij}) \quad (1)$$

$\Longleftrightarrow$

$$L(\theta_i, \alpha_i, \beta_i | x_{i[n]}) = (1 - \theta_i)^{n-m} \theta_i^m \prod_{j=1}^n (f_{Z_i}(x_{ij}) \mathbf{1}_{\{x \neq 0\}}(x_{ij}) + \mathbf{1}_{\{x=0\}}(x_{ij})) \quad (2)$$

där  $m = \sum_{j=1}^n \mathbf{1}_{\{x \neq 0\}}(x_{ij})$  alltså hur många gånger  $x_i$  inte är noll (gångar tävlaren  $i$  landade tricket). Nu tar vi log likelihoodfunktionen.

$$\implies \log(L) = (n - m) \log(1 - \theta_i) + m \log(\theta_i) + \sum_{j=1}^n \log(f_{Z_i}(x_{ij}) \mathbf{1}_{\{x \neq 0\}}(x_{ij}) + \mathbf{1}_{\{x=0\}}(x_{ij})) \quad (3)$$

$$\iff \partial_{\theta_i} \log(L) = \frac{m - n}{1 - \theta_i} + \frac{m}{\theta_i} = 0 \quad (4)$$

$$\iff \frac{m - n\theta_i}{\theta_i(1 - \theta_i)} = 0 \iff \hat{\theta}_i = \frac{m}{n} \quad (5)$$

MLE för bernoulli fördelningens  $V_i$  parameter  $\hat{\theta}_i = \operatorname{argmax}_{\theta \in \Omega} L(\theta_i | v_{i[n]}) = \bar{v}_i$  skulle ge oss samma resultat. Eftersom vi kan transformera stickprovet  $x_{i[n]} \rightarrow v_{i[n]}$  med anm 1  $v_i = \mathbf{1}_{\{x \neq 0\}}(x_i)$ . vilket betyder att  $m = \sum_{j=1}^n v_i$  och därmed får eq. (5) att sammanfalla med MLE av bernoulli fördelningen.

### (b) skatta $\alpha_i$ och $\beta_i$

Observera att från eq. (3)  $\sum_{j=1}^n \log(f_{Z_i}(x_{ij}) \mathbf{1}_{\{x \neq 0\}}(x_{ij}) + \mathbf{1}_{\{x=0\}}(x_{ij})) = \sum_{j=1}^n \log(f_{Z_i}(x_{ij}) \mathbf{1}_{\{x \neq 0\}}(x_{ij}))$  eftersom  $\log(1) = 0$ . Vi vet att  $\operatorname{argmax}_{\alpha, \beta \in \Omega} \log(L) = \operatorname{argmax}_{\alpha, \beta \in \Omega} \sum_{j=1}^n \log(f_{Z_i}(x_{ij}) \mathbf{1}_{\{x \neq 0\}}(x_{ij}))$  vilket är ekvivalent med  $\operatorname{argmax}_{\alpha, \beta \in \Omega} \log(L(\alpha, \beta | z_{i[k]}))$  för att  $z$  stickprovet innehåller alla trick som landade  $z_{i[k]} = (z_{i1}, \dots, z_{ik})^T = \{x_{ij} \in x_{i[n]} : x_{ij} \neq 0\}$   
Vi ska alltså bara maximera log-likelihood av beta fördelningens paramtrerna givet data from  $Z_i$

$$\begin{cases} \partial_{\alpha} \log(L(\alpha, \beta | z_{i[k]})) = \sum_{j=1}^k \partial_{\alpha} \log(f(z_{ij})) = 0 \\ \partial_{\beta} \log(L(\alpha, \beta | z_{i[k]})) = \sum_{j=1}^k \partial_{\beta} \log(f(z_{ij})) = 0 \end{cases}$$

$$\begin{aligned} \therefore \partial_{\alpha} \log(f(z_{ij})) &= \partial_{\alpha} \log\left(\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha) \cdot \Gamma(\beta)} \cdot z_{ij}^{\alpha-1} \cdot (1 - z_{ij})^{\beta-1}\right) \\ &= \partial_{\alpha} (\log \Gamma(\alpha + \beta) - \log \Gamma(\alpha) - \log \Gamma(\beta) + (\alpha - 1) \log z_{ij} + (\beta - 1) \log(1 - z_{ij})) \\ &= \partial_{\alpha} \log(f(z_{ij})) = \psi(\alpha + \beta) - \psi(\alpha) + \log z_{ij} \text{ där } \psi = \Gamma'/\Gamma \\ &\quad (\text{Vi gör liknande för } \partial_{\beta} \log f(z_{ij})) \end{aligned}$$

$$\Rightarrow \begin{cases} \partial_{\alpha} \log L = k\psi(\alpha + \beta) - k\psi(\alpha) + \sum_{j=1}^k \log(z_{ij}) = 0 \\ \partial_{\beta} \log L = k\psi(\alpha + \beta) - k\psi(\beta) + \sum_{j=1}^k \log(1 - z_{ij}) = 0 \end{cases}$$

### (c) Model för $Y_i$

$Y_i$  ska vara run betyget för åkaren  $i$ . Eftersom  $Y_i \in (0, 1]$  (varje deltagare får betyg större än 0) kommer bernoulli delen försvinna. Så vi antar att  $Y_i \sim \text{Beta}(\alpha_i, \beta_i)$ . Vi använder samma metod som vi använde för att skatta  $\alpha, \beta$  för  $X$ .

### (d) Simulering

Total betyget för varje deltagare beräknas som summan av deras två största trick betyg och största run betyg. Vi kan beskriva i termer av stokastiska variabler. Låt  $T_i$  vara total betyg för deltagare

*i.* Låt  $Z_{i,\text{först}} = \max(X_{i1}, X_{i2}, X_{i3}, X_{i4})$  och  
 $Z_{i,\text{andra}} = \max(\min(X_1, X_2), \min(X_1, X_3), \min(X_1, X_4), \min(X_2, X_3), \min(X_2, X_4), \min(X_3, X_4))$ .  
Vi vill simulera total betyg för varje deltagare  $i$  som  $T_i = Z_{i,\text{först}} + Z_{i,\text{andra}} + \max(Y_{i1}, Y_{i2})$

### **3 En bayesiansk modell**

### **4 En bayesiansk modell med en hierarki**

### **5 Diskussion**